

RELATÓRIO DE ANÁLISE

Detecção de Fraude em Transações

Fatores de risco, desempenho do modelo atual e recomendações priorizadas

Base analisada: 150.000 transações · grão de 1 linha por transação · rótulo de fraude (0/1).

Métrica central: taxa de fraude = média da coluna fraude. Prevalência global de 5,0% (classe rara).

1. Sumário executivo

A fraude nesta base é rara (5,0%), mas não é aleatória: concentra-se de forma previsível em dois eixos — o **valor da transação** e o **topo do score do modelo**. Isso abre uma oportunidade direta de operação: priorizar a revisão por esses eixos ataca a maior parte da perda com o menor esforço. Os cinco achados centrais:

Valor é o sinal mais forte	Compras acima de R\$ 500 têm 14,9% de fraude — mais de 3× a média. É o segmento de maior perda por transação.
Risco ≠ dinheiro	A faixa acima de R\$ 500 tem a maior taxa, mas a maior exposição em reais está na faixa intermediária (R\$ 100–500): ~43% de todo o valor exposto.
O modelo só separa no topo	O decil de maior score tem 21,3% de fraude (~4× a média), mas a faixa intermediária não ordena risco de forma confiável.
70% da fraude em 30% da fila	Ordenando pelo score, revisar os 30% de maior risco captura 70% de todas as fraudes; o decil mais alto sozinho concentra 43%.
Risco concentrado no Brasil	O Brasil é o único país acima da média (5,5%) e responde por 74% do volume; o Uruguai quase não registra fraude (1,0%).

Recomendação central: montar uma fila de revisão priorizada pelo score do modelo, com regra dura de revisão para tickets altos, e priorizar um ciclo de recalibração do modelo — direcionado à faixa de valor R\$ 100–500 (onde mora a maior exposição financeira) e aos decis intermediários de score (onde o modelo hoje ordena mal).

2. Contexto e método

O objetivo é entender onde a fraude se concentra e avaliar se o modelo de score já existente é útil na operação. A análise parte da tabela de modelagem `abt_fraude` (150.000 transações, uma linha por transação), construída a partir da junção das tabelas de compra e dos três blocos de score, com remoção de 200 registros de teste.

Como a fraude é uma classe rara (5,0%), a análise se apoia em **taxa de fraude** (a média da coluna `fraude`), e não em contagem absoluta — que favoreceria apenas os segmentos maiores. Ao comparar grupos, aplica-se um piso mínimo de volume para evitar conclusões sobre amostras pequenas demais. A exceção deliberada é a análise por faixa de valor, em que taxa de fraude e valor absoluto em reais são reportados lado a lado: sem isso, não se


enxerga que "onde está o risco" e "onde está o dinheiro" não coincidem. Todas as queries estão no arquivo `sql/queries_analiticas.sql` que acompanha este relatório.

Nota de qualidade de dados. A segmentação por faixa de valor usa CASE com ELSE para a faixa mais alta; como `NULL < 500` não é verdadeiro em SQL, eventuais `valor_compra` nulos caem na faixa "acima de R\$ 500". Recomenda-se checar `COUNT(*) WHERE valor_compra IS NULL` e isolar nulos numa faixa própria antes de reportar essa fatia como uma tese fechada.


3. Panorama do problema

150.000 transações	7.500 fraudes	5,0% taxa de fraude	R\$ 547 mil valor exposto
------------------------------	-------------------------	-------------------------------	-------------------------------------

Das 150 mil transações, 7.500 são fraudes — os 5,0% que servem de linha de base para todo o resto. O valor financeiro diretamente exposto em transações fraudulentas soma R\$ 547 mil. Vale notar que o ticket médio de uma fraude (R\$ 73) é cerca de 1,7× o ticket médio geral (R\$ 44): a fraude tende a buscar transações de maior valor — o que já antecipa o primeiro achado.



4. O valor da transação: sinal forte, leitura nuançada



Taxa de fraude por faixa de valor da compra.

O risco cresce de forma limpa e acentuada com o tamanho do ticket: de 4,6% nas compras até R\$ 100 para 8,8% na faixa intermediária e 14,9% acima de R\$ 500 — mais que o triplo da média. Embora o segmento acima de R\$ 500 seja pequeno em volume (1.037 transações), sua taxa de fraude o torna o mais crítico por transação e um candidato natural a revisão obrigatória.

Onde está o risco não é onde está o dinheiro

Olhar só a taxa é enganoso quando o objetivo é priorizar mitigação por real evitado. Cruzando a taxa com a exposição financeira de cada faixa, o cenário muda de forma importante:

Faixa de valor	% dos casos de fraude	% do valor exposto	Valor exposto	Perda média / fraude
até R\$ 100	~84%	~31%	R\$ 170 mil	~R\$ 27
R\$ 100-500	~14%	~43%	R\$ 233 mil	~R\$ 226
acima de R\$ 500	~2%	~26%	R\$ 144 mil	~R\$ 931

Percentuais de casos reconstruídos a partir das taxas de fraude arredondadas — servem para dimensionar a divergência entre casos e exposição, não como número contábil exato.

Ressalva. Como `NULL < 500` não é verdadeiro em SQL, eventuais `valor_compra` nulos caem na faixa "acima de R\$ 500" — os números dessa faixa podem estar levemente contaminados. Diagnóstico completo dos nulos é a primeira checagem sugerida antes de fechar decisão sobre essa faixa (ver Seção 2).

Três leituras práticas saem dessa tabela:

Faixa acima de R\$ 500 — revisão obrigatória. Maior taxa (14,9%) e maior perda por caso (~R\$ 931), com volume pequeno (~1.037 transações). Custo operacional de revisão baixo, retorno alto. É a regra dura mais natural do sistema.


Faixa R\$ 100-500 — onde o modelo tem a maior alavancagem. Concentra ~43% de todo o valor exposto, mas o volume é grande demais para revisar tudo na mão. É o segmento em que investir em score/modelo mais reduz perda em reais — e é justamente onde o score hoje ordena mal (ver seção 5).

Faixa até R\$ 100 — automação e uma pergunta em aberto. 84% dos casos, mas só ~R\$ 27 de perda média — dificilmente justifica revisão manual. A menos que essas microfraudes façam parte de um padrão de card testing (micro-compras seguidas de uma compra grande no mesmo cartão), o que mudaria completamente a leitura. Vale investigar em uma próxima iteração.

Uma limitação honesta: taxa de fraude não é o mesmo que o limiar de um modelo. A escolha de onde cortar depende do custo relativo entre bloquear um cliente bom (falso positivo, atrito) e deixar passar fraude (falso negativo, perda). Esses números dão a base de perda por faixa, mas não o trade-off de precisão/recall — para isso é preciso simular limiares contra o custo de cada tipo de erro.

5. Desempenho do modelo atual

O modelo só separa bem no topo — e o meio é irregular




Taxa de fraude por decil do score do modelo (1 = menor score, 10 = maior).

Dividindo a base em dez faixas iguais pelo `score_fraude_modelo`, o decil mais alto concentra 21,3% de fraude — cerca de quatro vezes a média. Esse é o comportamento desejado no topo. Porém, a faixa intermediária é irregular: o decil 4, por exemplo, tem menos fraude (0,3%) que o decil 1 (2,8%). Ou seja, o score é excelente para destacar os casos mais arriscados, mas **não ordena risco de forma confiável no meio da distribuição**.

Consequência prática: o score deve ser usado como **fila de prioridade** (quem revisar primeiro), e não como um corte único de decisão. Uma métrica de acurácia agregada esconderia essa limitação — por isso a avaliação por decis é mais honesta.

6. Priorização: 70% da fraude em 30% da fila

Priorizar pelo score concentra a fraude




Fração da fraude total capturada ao revisar os X% de maior score.

Apesar da irregularidade no meio, o topo do score é tão denso em fraude que priorizar a fila por ele rende muito mais que uma revisão aleatória. Revisando apenas os 10% de maior score já se captura 43% de toda a fraude; nos 30% de maior score, chega-se a 70%. Para a operação, isso significa que é possível concentrar o esforço de revisão manual em um terço da fila e ainda assim alcançar a maioria dos casos — uma redução direta de carga sem perder cobertura.

7. Concentração geográfica

Só o Brasil está acima da média geral



Taxa de fraude por país, apenas países com ao menos 1.000 transações.

Entre os quatro países com volume relevante, apenas o Brasil está acima da média geral (5,5%), enquanto o Uruguai é o mais seguro (1,0%). Como o Brasil também responde pela maior parte do volume, ele domina a taxa consolidada. Isso sugere calibrar regras e limiares por país, em vez de aplicar o mesmo rigor a todas as praças. O corte de 1.000 transações é deliberado: sem ele, países com pouquíssimas compras apareceriam com taxas extremas apenas por ruído estatístico.

8. Comportamento no tempo

A base cobre dois meses (março e abril de 2020), com taxas praticamente idênticas (5,04% e 4,96%). Não há sinal de sazonalidade a explorar nesse intervalo — o que, em si, é uma conclusão útil: evita atribuir tendência temporal a um período curto demais para sustentá-la.

9. Recomendações priorizadas

1

Fila de revisão priorizada pelo score

Ordenar a revisão manual pelo score do modelo e concentrar esforço nos 30% de maior risco — cobre ~70% da fraude com muito menos fila.

2

Regra dura para ticket alto

Revisão obrigatória para compras acima de R\$ 500, segmento com 14,9% de fraude e maior perda por caso (~R\$ 931). Simples de implementar e ataca o segmento de maior risco por transação.

3 Recalibrar o modelo com foco duplo

Priorizar dois cortes na próxima iteração de modelo: a faixa de valor R\$ 100–500 (onde mora ~43% da exposição financeira e o modelo hoje não é usado como discriminador forte) e os decis intermediários de score (onde a ordenação de risco quebra). Corrigir esses dois pontos melhora toda a fila de priorização — é o item de maior alavancagem no médio prazo.

4 Limiares por país

Calibrar regras por praça: o Brasil concentra risco e volume; o Uruguai exige menos rigor. Evita tratar mercados muito diferentes com o mesmo critério.

5 Investigar card testing na faixa até R\$ 100

Baixo ticket concentra 84% dos casos, mas só ~R\$ 27 de perda média — não justifica revisão manual isolada. Vale checar se essas microfraudes antecedem compras grandes do mesmo cartão/cliente; se sim, a leitura da faixa muda e a regra de bloqueio deve olhar padrão, não valor.

Apêndice — resumo numérico

Análise	Resultado principal
Panorama	150.000 transações · 7.500 fraudes · 5,0% · R\$ 547.271 expostos
Ticket médio	Fraude R\$ 72,97 vs. geral R\$ 43,52 (~1,7×)
Faixa de valor — taxa	≤100: 4,60% · 100–500: 8,84% · >500: 14,95%
Faixa de valor — exposição	≤100: R\$ 170 mil (31%) · 100–500: R\$ 233 mil (43%) · >500: R\$ 144 mil (26%)
Faixa de valor — perda média	≤100: ~R\$ 27 · 100–500: ~R\$ 226 · >500: ~R\$ 931
Decis do score	Decil 10: 21,3% (~4× a média); meio não-monotônico
Captura acumulada	10% da fila → 43% · 30% → 70% · 50% → 77%
País (≥1.000)	BR 5,52% · AR 3,69% · US 3,08% · UY 0,98%
Tempo	2020-03: 5,04% · 2020-04: 4,96% (sem sazonalidade)

As queries que produzem cada número acima estão em `sql/queries_analiticas.sql`. Métrica de taxa = $100 \times \text{média de fraude}$.